

TP1-ADM

Guillaume Bernard-Reymond et Lorenzo Gaggini

October 2023

Dans ce TP, nous avons à notre disposition un tableau contenant une liste de 21 vins dont on a mesuré différents paramètres. En voici un extrait :

	X	Label	Soil	Odor.Intensity.before.shaking	Aroma.quality.before.shaking
1	2EL	Saumur	Env1	3.074	3.000
2	1CHA	Saumur	Env1	2.964	2.821
3	1FON	Bourgueuil	Env1	2.857	2.929
4	1VAU	Chinon	Env2	2.808	2.593

Table 1: Extrait du tableau

1 Partie 1

Dans cette partie, nous désignerons par (x_i) où $i \in \{1; \dots; 21\}$ les individus et (x^j) où $j \in \{1; \dots; 32\}$ les variables, qu'elles soient quantitatives ou bien qualitatives. Enfin nous noterons (z^j) où $j \in \{4; \dots; 32\}$ les variables quantitatives centrées-réduites.

1. Dans cette question nous placerons dans le cas général où $i \in \{1; \dots; n\}$ et $j \in \{1; \dots; p\}$

- On considère $(w_i)_{i \in \{1 \dots n\}}$ une suite de poids telle que $\sum_{i=1}^n w_i = 1$ et soit $j \in \{1; \dots; p\}$. On peut alors écrire :

$$\begin{aligned}\sum_{i=1}^n w_i z_i^j &= \sum_{i=1}^n w_i \left(\frac{x_i^j - \bar{x}^j}{\sigma_{x^j}} \right) \\ &= \frac{1}{\sigma_{x^j}} \sum_{i=1}^n (w_i x_i^j - w_i \bar{x}^j) \\ &= \frac{1}{\sigma_{x^j}} \left(\bar{x}^j - \bar{x}^j \sum_{i=1}^n w_i \right) \\ &= 0\end{aligned}$$

Le barycentre du nuage est donc bien $0_{\mathbb{R}^p}$.

Informatiquement, voici un extrait de ce que nous avons obtenu :

	Odor.Intensity.before.shaking	Aroma.quality.before.shaking	Fruity.before.shaking	Flower.before.shaking
1	-0.000	0.000	-0.000	0.000

Table 2: extrait du tableau des barycentres

```
Barycentre=(colMeans(CR[4:32]))  
print(Barycentre)
```

Les résultats obtenus étant de l'ordre de 10^{-16} , on peut considérer qu'ils sont égaux à 0.

•

$$\begin{aligned}
In_O(\{z_i; w_i\}_{i=1, \dots, n}) &= \sum_{i=1}^n w_i \|z_i\|^2 \\
&= \sum_{i=1}^n w_i \left(\sum_{j=1}^p z_i^j{}^2 \right) \\
&= \sum_{i=1}^n \left(\sum_{j=1}^p w_i z_i^j{}^2 \right) \\
&= \sum_{j=1}^p \left(\sum_{i=1}^n w_i z_i^j{}^2 \right)
\end{aligned}$$

Or l'expression $\sum_{i=1}^n w_i z_i^j{}^2$ n'est rien d'autre que l'expression de la variance de notre variable quantitative centrée réduite qui vaut donc 1.

Ainsi : $In_O(\{z_i; w_i\}_{i=1, \dots, n}) = p$ c'est à dire le nombre de variables quantitatives.

Informatiquement, voici ce que nous avons obtenu :

	Odor.Intensity.before.shaking	Aroma.quality.before.shaking	Fruity.before.shaking	Flower.before.shaking
1	1.000	1.000	1.000	1.000

Table 3: extrait du tableau des variances

```

#variance
Variance=diag(var(CR[4:32]))
print(Variance)

#inertia
Inertie=sum(Variance)
print(Inertie)

```

Le résultat obtenu est 29 comme attendu.

2. Pour chaque appellation, nous avons effectuer un tri afin d'obtenir pour chaque appellation un tableau des individus. A partir de là, nous avons calculé le poids, les barycentres et les normes euclidiennes carrées de ces trois barycentres. Voici le code utilisé où CR désigne le tableau dont les variables quantitatives sont centrées et réduites :

Voici un extrait d'un des tableaux :

	X	Label	Soil	Odor.Intensity.before.shaking	Aroma.quality.before.shaking
4	1VAU	Chinon	Env2	-1.047	-2.202
9	DOM1	Chinon	Env1	-0.878	-1.122
17	2BEA	Chinon	Reference	-0.260	0.648

Table 4: extrait du tableau de l'appellation Chinon

```

"Q2"
chinon=CR[CR$Label == 'Chinon',]
saumur=CR[CR$Label == 'Saumur',]
bourgueuil=CR[CR$Label == 'Bourgueuil',]

```

```

#poids
pchi=nrow(chinon)/nrow(CR)
psau=nrow(saumur)/nrow(CR)
pbou=nrow(bourgueuil)/nrow(CR)

```

```
#barycentre
mchi= unname(colMeans(chinon[4:32]))
msau= unname(colMeans(saumur[4:32]))
mbou= unname(colMeans(bourgueuil[4:32]))

#carree des normes euclidiennes des barycentres
nchi=sum(mchi^2)
nsau=sum(msau^2)
nbou=sum(mbou^2)
```

Voici les résultats obtenus :

	Poids	Norme
Chinon	0,1905	5,1428
Saumur	0,5338	2,0188
Bourgueuil	0,2857	3,4319

Pour chaque variable sensorielle, nous avons calculer le R^2 . Nous avons donc obtenu 3 vecteurs lignes de 29 valeurs. Nous avons ensuite triés les valeurs et tracés les graphiques correspondant.

Pour le Bourgueil :

- la moins liée : Spice.before.shaking
- la plus liée : Attack.intensity

Pour le Chinon :

- les moins liées : Spice.before.shaking et Astringency
- les plus liées par ordre croissant : Fruity , Aroma.intensity , Acidity

Pour le Saumur :

- la moins liée : Surface.feeling
- les plus liées par ordre croissant : Flower , Spice , Spice.before.shaking.

Montrons que le R^2 de la partition est égal à la moyenne arithmétique des R^2 des variables que l'on notera M .

$$\begin{aligned}
M &= \frac{1}{29} \sum_{j=1}^{29} \frac{\text{Variance externe de la variable } j}{\text{Variance totale de la variable } j} \\
&= \frac{1}{29} \sum_{j=1}^{29} \frac{\sum_{k=1}^3 W^k \left(\overline{x^j}^k\right)^2}{1} \\
&= \frac{1}{29} \sum_{k=1}^3 W^k \sum_{j=1}^{29} \left(\overline{x^j}^k\right)^2 \\
&= \frac{1}{29} \sum_{k=1}^3 W^k \|\overline{x^k}\|^2 \\
&= R_{\text{partition}}^2
\end{aligned}$$

A faire informatiquement.

2 Partie 2

1. (a) On considère le vecteur $\mathbb{1}_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^n$.

On rappelle que $\mathbb{1}_n \in \text{Vect}(y^1; \dots; y^p) = \langle Y \rangle$ car $\forall i \in \{1; \dots; n\}$, $\sum_{j=1}^p \mathbb{1}_{Y_i=j} = 1$ donc $\mathbb{1}_n \in \langle Y \rangle$. Soit $j \in \{1; \dots; p\}$:

$$\begin{aligned} \Pi_{\langle Y \rangle} x^j &= \Pi_{\langle \mathbb{1}_n \rangle} x^j + \Pi_{\langle \mathbb{1}_n^\perp \cap Y \rangle} x^j \text{ car } \langle Y \rangle = \langle \mathbb{1}_n \rangle \oplus \langle \mathbb{1}_n^\perp \cap Y \rangle \\ &= 0 + \Pi_{\langle Y^c \rangle} x^j \\ &= \Pi_{\langle Y^c \rangle} x^j \end{aligned}$$

$\Pi_{\langle \mathbb{1}_n \rangle} x^j = 0$ car x^j étant centré réduit, il appartient à $\mathbb{1}_n^\perp$.

$\|\Pi_Y x^j\|_W^2$ représente la variance de la variable x^j par rapport à l'appellation.

- (b) $\Pi_Y = Y(Y'WY)^{-1}Y'W$ est une matrice carrée de taille 21 et de même pour $\Pi_{x^j} = x^j(x^{j'}Wx^j)^{-1}x^{j'}W$
- (c) $\text{tr}(R\Pi_Y)$ est le R^2 de la partition des vins en appellations.
- (d)
2. De la même façon, $\text{tr}(\Pi_{x^j}\Pi_Z)$ est ... et $\text{tr}(R\Pi_Z)$ est le R^2 de la partition des vins selon les types de sol.